

CASE COMUNIDADOS

Projeto de Dados em uma Indústria Farmacêutica

Discovery, levantamento de requisitos e entendimento do problema antes da construção da solução.

Objetivo

Você receberá um cenário empresarial complexo e propositalmente incompleto. Sua missão será escolher um papel dentro do projeto e construir um processo de investigação capaz de reduzir as incertezas antes que qualquer solução seja desenvolvida.

1. Contexto da empresa

Você foi contratado para participar de um novo projeto de dados em uma grande indústria farmacêutica. A empresa possui uma fábrica responsável pela produção de diferentes medicamentos e opera 24 horas por dia, dividida em múltiplas linhas de produção.

A operação envolve diferentes áreas trabalhando de forma integrada, como Produção, Planejamento, Qualidade, Manutenção, Logística, Estoque, Tecnologia, Engenharia Industrial e áreas corporativas.

Apesar da empresa possuir uma grande quantidade de dados, essas informações estão distribuídas entre diferentes sistemas, bancos de dados, arquivos e equipamentos industriais. Cada área desenvolveu ao longo dos anos sua própria forma de registrar, consultar e acompanhar as informações.

Como consequência, a empresa possui dados relevantes, porém ainda encontra dificuldade para utilizá-los de maneira integrada na tomada de decisão.

Principais fontes existentes

- **ERP:** ordens de produção, materiais, estoque, fornecedores, custos, compras e planejamento.
- **MES:** execução das ordens de produção, etapas produtivas, lotes, apontamentos e informações operacionais.
- **Sensores e equipamentos IoT:** telemetria gerada continuamente pelas máquinas e linhas de produção.
- **Sistemas de qualidade:** inspeções, desvios, rejeições, resultados laboratoriais e registros de qualidade.
- **Sistemas de manutenção:** equipamentos, ordens de manutenção, falhas, intervenções e paradas.
- **Arquivos CSV e Excel:** controles paralelos mantidos por algumas áreas.
- **Bancos SQL:** aplicações internas e sistemas departamentais.
- **APIs:** fornecedores, parceiros e sistemas terceiros.

Características dos dados

As fontes possuem comportamentos bastante diferentes. Algumas informações são atualizadas apenas uma vez por dia. Outras são alteradas diversas vezes ao longo do expediente. Sensores da fábrica podem gerar milhares ou milhões de registros continuamente.

Também não existe ainda uma definição corporativa sobre quais informações precisam ser processadas em tempo real, quais podem possuir alguns minutos de atraso e quais podem ser processadas somente em cargas batch.

Outro ponto importante é que os sistemas foram implantados em momentos diferentes. Isso significa que podem existir diferenças de identificadores, granularidade, histórico, qualidade e regras de negócio entre as fontes.

2. O problema atual

A diretoria identificou que atualmente é difícil obter uma visão integrada da operação. Quando ocorre uma redução na produtividade de determinada linha, diferentes equipes precisam consultar sistemas diferentes para tentar descobrir o motivo.

Por exemplo, uma equipe pode consultar o sistema de produção para verificar a quantidade produzida, enquanto outra consulta o sistema de manutenção para procurar falhas em equipamentos. O time de qualidade pode precisar consultar outra aplicação para verificar desvios do lote, enquanto o planejamento

utiliza planilhas e informações do ERP para comparar o realizado com o previsto.

Esse processo torna a análise lenta, aumenta a dependência de conhecimento individual e dificulta encontrar rapidamente a causa de problemas operacionais.

A empresa decidiu iniciar um projeto para criar uma visão mais integrada dos dados da fábrica e melhorar a capacidade de análise e tomada de decisão.

3. Domínios que poderão fazer parte do projeto

Domínio	Informações disponíveis ou esperadas
Produção	Quantidade produzida, lote, medicamento, linha, horário de início e término, velocidade da linha, quantidade planejada e realizada.
Planejamento	Ordens previstas, demanda, capacidade produtiva, planejamento semanal e mensal, previsão de produção e alterações no planejamento.
Qualidade	Lotes aprovados e rejeitados, inspeções, desvios, resultados laboratoriais, motivos de rejeição e indicadores de qualidade.
Manutenção	Equipamentos, paradas programadas e não programadas, tipo de falha, duração da parada e histórico de manutenção.
IoT e sensores	Temperatura, pressão, umidade, vibração, velocidade de equipamentos e demais telemetrias.
Estoque e logística	Matéria-prima disponível, movimentações, produtos acabados, expedição e disponibilidade de materiais.

4. Necessidades iniciais apresentadas pelo negócio

Durante a primeira reunião, o diretor industrial apresenta uma demanda aparentemente simples:

"Precisamos utilizar nossos dados para entender melhor a fábrica, identificar problemas mais rapidamente e melhorar nossa eficiência."

Quando questionado sobre o que exatamente precisa ser desenvolvido, ele apresenta algumas ideias, mas nenhuma delas foi detalhada tecnicamente.

- A diretoria gostaria de acompanhar a produção praticamente em tempo real.
- Os gestores querem comparar planejado x realizado.
- O time de qualidade quer identificar rapidamente desvios de produção.
- A manutenção quer entender quais equipamentos estão causando mais interrupções.
- O planejamento quer prever possíveis atrasos.
- Existe interesse futuro em utilizar Machine Learning para prever falhas de equipamentos e problemas na produção.

Até este momento, porém, não existe uma definição consolidada de arquitetura, indicadores, regras de negócio, requisitos técnicos, modelos analíticos, prioridades, SLAs ou critérios de sucesso.

Esse é exatamente o cenário que você recebeu.

5. Seu desafio

Você ainda não deve construir nenhuma solução. Não escolha Databricks, Fabric, AWS, Azure, Kafka, Airflow, Power BI ou qualquer outra ferramenta neste momento.

Antes disso, você precisa entender o problema, identificar as pessoas certas, levantar informações, descobrir restrições e reduzir as incertezas do projeto.

Você deverá escolher um dos três papéis:

Papel	Responsabilidade principal
Arquitetura e Engenharia de Dados	Descobrir como os dados poderão ser coletados, integrados, armazenados, processados e disponibilizados.
Análise de Dados	Descobrir quais informações, indicadores e análises realmente precisam ser entregues ao negócio.
Ciência de Dados	Descobrir quais problemas podem ser tratados com modelos estatísticos ou Machine Learning e se existem condições para isso.

6. Papel 1: Arquitetura e Engenharia de Dados

Imagine que você será responsável por entender como os dados sairão dos diferentes sistemas da fábrica e chegarão até uma plataforma capaz de atender às necessidades da empresa.

Existem dados de produção, planejamento, qualidade, manutenção, estoque e sensores. Alguns são batch, outros são gerados continuamente.

Antes de desenhar qualquer arquitetura ou escolher tecnologias, você precisa realizar um levantamento completo do ambiente.

Somente como ponto de partida, considere estas duas perguntas:

1. Quais são as fontes de dados existentes e como podemos acessar cada uma delas?
2. Quais informações realmente precisam ser processadas em tempo real e quais podem ser processadas em batch?

A partir daqui é responsabilidade do aluno desenvolver todo o restante do roteiro.

O aluno deverá pensar sobre fontes, integrações, infraestrutura, volume, velocidade, histórico, segurança, governança, qualidade, disponibilidade, armazenamento, processamento, consumo, monitoramento, custos e demais aspectos que considerar relevantes.

O objetivo é chegar ao final do Discovery com informações suficientes para posteriormente propor uma arquitetura e uma estratégia de engenharia de dados.

7. Papel 2: Análise de Dados

Aqui seu objetivo é entender quais informações realmente precisam ser entregues para que as áreas da fábrica consigam tomar melhores decisões.

A diretoria quer uma visão integrada da operação, mas ainda não existe uma definição clara dos indicadores, análises, dashboards ou regras de negócio necessárias.

Somente como ponto de partida, considere estas duas perguntas:

1. Quais decisões o negócio espera tomar utilizando esses dados?
2. Quais são atualmente os principais indicadores utilizados para avaliar a eficiência da produção?

O restante deverá ser desenvolvido pelo aluno.

Você deverá descobrir quais pessoas precisam ser entrevistadas, quais processos precisam ser entendidos, quais regras de negócio precisam ser documentadas e quais perguntas são necessárias para transformar a demanda inicial em requisitos analíticos claros.

O objetivo não é desenhar um dashboard. O objetivo é entender o que precisa ser analisado, por quem, para quê e como essa informação ajudará na tomada de decisão.

8. Papel 3: Ciência de Dados

A diretoria acredita que os dados da fábrica também poderiam ser utilizados para prever problemas, antecipar falhas e melhorar a eficiência da operação.

Porém, dizer que a empresa quer utilizar Inteligência Artificial ou Machine Learning ainda não representa um problema de Ciência de Dados bem definido.

Seu primeiro trabalho será investigar se existe realmente um problema que possa ser resolvido utilizando modelos.

Somente como ponto de partida, considere estas duas perguntas:

1. Qual evento ou comportamento exatamente queremos prever?
2. O que o negócio fará quando o modelo identificar que esse evento provavelmente acontecerá?

A partir dessas perguntas iniciais, o aluno deverá construir todo o processo investigativo.

Será necessário entender o problema de negócio, os dados disponíveis, histórico, eventos, variáveis, qualidade, viabilidade, impacto esperado, métricas de sucesso e demais aspectos considerados importantes.

O objetivo é chegar ao final do Discovery conseguindo responder: existe realmente um problema de Ciência de Dados aqui? Caso exista, temos dados e condições suficientes para tentar resolvê-lo?

9. Entrega do desafio

O aluno deverá escolher apenas um dos três papéis e assumir que foi contratado para participar das primeiras etapas desse projeto.

1. Papel escolhido e responsabilidades assumidas.
2. Interpretação inicial do problema apresentado.
3. Stakeholders que deveriam participar do Discovery.
4. Informações que ainda precisam ser descobertas.
5. Etapas que realizaria antes do início do desenvolvimento.
6. Roteiro das reuniões de Discovery.
7. Perguntas que faria para cada stakeholder.
8. Motivo pelo qual essas perguntas são importantes.
9. Principais riscos que tentaria identificar antes do início.
10. Dependências que precisam ser levantadas.
11. Critérios para considerar o Discovery concluído.
12. Próximos passos recomendados depois do levantamento.

10. Orientações

Não existe uma quantidade máxima de perguntas. Quanto mais completo for o levantamento, melhor, desde que as perguntas tenham propósito e estejam relacionadas ao projeto.

Também não existe uma única resposta correta. O que será avaliado é a capacidade do aluno de investigar, organizar o problema, identificar informações ausentes e reduzir incertezas antes de propor uma solução.

11. Regra principal do case

Neste momento você não deve construir a solução.

Não queremos inicialmente uma arquitetura pronta, um dashboard ou um modelo de Machine Learning. Também não queremos que sua primeira preocupação seja escolher entre Azure, AWS, Databricks, Fabric, Kafka, Airflow ou qualquer outra tecnologia.

Um arquiteto pode propor uma arquitetura tecnicamente excelente e resolver o problema errado. Um engenheiro pode construir pipelines eficientes com dados que ninguém precisa. Um analista pode criar diversos dashboards que não ajudam ninguém a tomar decisões. Um cientista pode construir um modelo com ótima métrica técnica que não gera nenhuma ação para o negócio.

Você recebeu um problema complexo e incompleto. Agora precisa descobrir tudo que precisa saber antes de começar a resolvê-lo.

Um bom projeto de dados começa antes do código.